
Informalidad laboral en Argentina: un problema real, la EPH como fuente y el Machine Learning como herramienta

Clasificación binaria de personas ocupadas formales e informales

"Instructivo de Pre-Curación del set de Datos"

Objetivo del documento

Este documento describe todas las columnas del conjunto de datos utilizado en la mentoría, indicando su origen en la EPH, su significado conceptual y cómo fue construida o transformada a partir de los datos originales del INDEC.

Fuente de datos: INDEC – Encuesta Permanente de Hogares, 3° Trimestre del 2025
Archivos provistos: EPH_individuos_T325.csv y EPH_hogares_T325.csv
DiploDatos 2026

Contenidos

1	Introducción y Metodología de Construcción	2
1.1	Descripción de los archivos provistos	2
1.2	Proceso de construcción del conjunto de datos	2
2	Identificación	3
3	Variables Geográficas	3
4	Características de la Vivienda	3
5	Características Habitacionales del Hogar	4
6	Estrategias del Hogar	5
7	Composición del Hogar e Ingresos del Hogar	5
8	Características Personales del Individuo	6
9	Condición Laboral	7
9.1	Variables de condición y clasificación laboral	7
9.2	Variables de ingresos	7
10	Variables de Jornada Laboral	7
11	Variables Derivadas	8
11.1	Actividad Económica	8
11.2	Variables del Clasificador Nacional de Ocupaciones (CNO)	9
11.3	Antigüedad Laboral	10
11.4	Aporta Jubilación	10
11.5	Tamaño Empresa	11
11.6	Horas Mensuales Estimadas	12
12	Consideraciones Finales	13

1 Introducción y Metodología de Construcción

1.1 Descripción de los archivos provistos

Se entregan **dos archivos** en formato CSV, contruidos a partir de las bases originales de la EPH del tercer trimestre de 2025, publicadas por el INDEC:

- **EPH_individuos_T325.csv**: contiene información sociodemográfica y laboral de cada persona ocupada encuestada, junto con variables derivadas. Cada fila representa un **individuo ocupado**.
- **EPH_hogares_T325.csv**: contiene información sobre las características de la vivienda, el hogar y su composición. Cada fila representa un **hogar**. Un hogar puede tener más de un individuo en el archivo de individuos.

Ambos archivos comparten las claves **Código Vivienda** y **Número de Hogar**, que permiten vincular la información de cada individuo con la de su hogar.

1.2 Proceso de construcción del conjunto de datos

Los archivos provistos fueron contruidos a partir de las bases originales del INDEC en tres etapas:

1. **Filtrado de la población de interés**: se retuvieron únicamente los registros que cumplen tres criterios simultáneos:
 - Edad en rango laboral (18 a 65 años).
 - Condición de actividad: **ocupado**.
 - Clasificación de empleo disponible (Formal o Informal).

Esto arrojó un total de **19.269 registros** y **~12.000 hogares** únicos.

2. **Selección, renombramiento y recodificación de columnas**: se seleccionaron las columnas relevantes de las bases originales, se renombraron con nombres descriptivos en español y se recodificaron los valores numéricos a etiquetas interpretables. Los valores especiales del INDEC (códigos 9, 99, 9999 equivalentes a NS/NR) fueron convertidos a NaN.
3. **Construcción de variables derivadas**: se construyeron nuevas variables a partir de las columnas originales, incluyendo la unificación de columnas equivalentes entre distintos tipos de personas con ocupacion ((asariados e independientes), la decodificación de los clasificadores CAES-Mercosur y CNO, y el cálculo de variables sintéticas como **Horas Mensuales Estimadas**.

2 Identificación

Estas columnas identifican unívocamente a cada registro y están presentes en **ambos archivos** como claves de vinculación para el merge.

Columna	Origen EPH	Descripción
Código Vivienda	CODUSU	Código alfanumérico de 29 caracteres que identifica una vivienda en la muestra. Permite vincular individuos con hogares y hacer seguimiento a lo largo de los trimestres.
Número de Hogar	NRO_HOGAR	Número que distingue hogares dentro de una misma vivienda. Una vivienda puede contener más de un hogar. La combinación CODUSU + NRO_HOGAR identifica únicamente a cada hogar.

3 Variables Geográficas

Caracterizan la ubicación geográfica del hogar encuestado. Proviene de la base de hogares.

Columna	Origen EPH	Descripción
Región	REGION	Región geográfica del país donde se ubica el hogar.
Tipo de Aglomerado	MAS_500	Indica si el aglomerado tiene más o menos de 500.000 habitantes.
Aglomerado	AGLOMERADO	Nombre del aglomerado urbano encuestado. La EPH cubre 33 aglomerados del país.

4 Características de la Vivienda

Describen las condiciones físicas y de infraestructura de la vivienda. Son indicadores del nivel socioeconómico estructural del hogar. Proviene de la base de hogares.

Columna	Origen EPH	Descripción
Tipo de Vivienda	IV1	Tipo de construcción de la vivienda, relevado por observación del encuestador.
Material del Piso	IV3	Material predominante de los pisos interiores de la vivienda. Proxy de calidad constructiva.
Material del Techo	IV4	Material de la cubierta exterior del techo. Proxy de precariedad habitacional.
Tipo de Acceso al Agua	IV6	Indica cómo accede la vivienda al agua.

(Continuación)

Columna	Origen EPH	Descripción
Tipo de Fuente de Agua	IV7	Origen o procedencia del agua que abastece la vivienda.
Tipo de Desagüe del Baño	IV11	Sistema de desagüe del baño o letrina. Indicador de saneamiento básico.
Cercanía a Basural	IV12_1	Indica si la vivienda está ubicada a 3 cuadras o menos de un basural.
Zona Inundable	IV12_2	Indica si la vivienda está en una zona que se inundó en los últimos 12 meses.
Villa de Emergencia	IV12_3	Indica si la vivienda está ubicada en una villa de emergencia (por observación).

5 Características Habitacionales del Hogar

Describen el uso y condiciones del espacio habitacional del hogar (no de toda la vivienda). Un hogar puede compartir vivienda con otros hogares. Proviene de la base de hogares.

Columna	Origen EPH	Descripción
Ambientes Exclusivos del Hogar	II1	Cantidad de ambientes/habitaciones del hogar para uso exclusivo, excluyendo baño, cocina, pasillos, lavadero y garage.
Cuartos p/Dormir	II2	De los ambientes exclusivos, cuántos se usan habitualmente para dormir. Permite calcular el hacinamiento : IX_TOT/Cuartos p/Dormir.
Es Lugar de Trabajo	II3	Indica si alguno de los ambientes del hogar es usado exclusivamente como lugar de trabajo (consultorio, taller, negocio, etc.).
Tipo de Tenencia de Vivienda	II7	Régimen de tenencia del hogar respecto a la vivienda que habita.
Tipo de Combustible de Cocina	II8	Combustible utilizado principalmente para cocinar. Proxy de acceso a servicios básicos.
Tipo de Tenencia del Baño	II9	Indica si el baño es de uso exclusivo del hogar o compartido con otros hogares.

6 Estrategias del Hogar

Estas columnas registran las fuentes de ingresos y estrategias económicas del hogar en los últimos 3 meses. Son especialmente valiosas porque capturan el comportamiento económico del hogar bajo presión. Proviene de la base de hogares. Todas las columnas son de tipo **Sí / No**.

Columna	Origen EPH	Descripción
Hogar Vive del Trabajo	V1	En los últimos 3 meses, ¿las personas del hogar vivieron de lo que ganan en el trabajo?
Hogar Vive de Jubilación	V2	En los últimos 3 meses, ¿vivieron de alguna jubilación o pensión?
Hogar Vive de AUH	V5_01	¿El hogar percibe la Asignación Universal por Hijo (AUH) y/o Asignación por Embarazo? Nota: La AUH está condicionada a no tener empleo formal registrado, por lo que esta variable tiene correlación directa con la informalidad laboral del hogar.
Hogar Vive de Plan Social	V5_02	¿El hogar percibe otro plan social o subsidio en dinero otorgado por el gobierno?
Recibe Mercadería Estado/Iglesia	V6	¿El hogar recibió mercadería, ropa o alimentos del gobierno, iglesias o escuelas?
Recibe Mercadería Familiar/Vecinos	V7	¿El hogar recibió mercadería, ropa o alimentos de familiares, vecinos u otras personas que no viven en el hogar?
Gastó Ahorros	V13	¿El hogar tuvo que gastar lo que tenía ahorrado? Indica presión económica.
Pidió Préstamo Familiar	V14	¿El hogar tuvo que pedir préstamos a familiares o amigos?
Pidió Préstamo Bancario	V15	¿El hogar tuvo que pedir préstamos a bancos o financieras?
Vendió Pertenencias	V17	¿El hogar tuvo que vender alguna de sus pertenencias? Máximo indicador de presión económica.

7 Composición del Hogar e Ingresos del Hogar

Resumen cuantitativo de la composición y los ingresos del hogar. Proviene de la base de hogares.

Columna	Origen EPH	Descripción
Cantidad de Miembros Hogar	IX_TOT	Total de personas que componen el hogar.
Cantidad de Menores de 10	IX_MEN10	Cantidad de miembros del hogar menores de 10 años. Indicador de carga familiar.

(Continuación)

Columna	Origen EPH	Descripción
Ingreso Total Hogar	ITF	Suma de los ingresos individuales totales de todos los miembros del hogar (laborales y no laborales). Calculado por INDEC. Expresado en pesos corrientes.
Ingreso p/Cápita Hogar	IPCF	Ingreso Total del Hogar dividido la cantidad de miembros (ITF / IX_TOT). Más informativo que el ITF bruto porque pondera por el tamaño del hogar.

8 Características Personales del Individuo

Información sociodemográfica de cada persona encuestada. Proviene de la base de individuos.

Columna	Origen EPH	Descripción
Parentesco	CH03	Relación de parentesco con el/la jefe/a del hogar.
Sexo	CH04	Sexo biológico del individuo.
Edad	CH06	Edad en años cumplidos al momento del relevamiento. Nota: el conjunto de datos fue filtrado para incluir únicamente personas entre 18 y 65 años.
Estado Civil	CH07	Estado conyugal actual del individuo.
Cobertura Médica	CH08	Tipo de cobertura médica que posee el individuo. Nota: puede ser indicador parcial de formalidad laboral, ya que la obra social suele ser un beneficio del empleo registrado.
Sabe Leer/Escribir	CH09	Indica si el individuo sabe leer y escribir.
Tipo de Establecimiento Educativo	CH11	Tipo de establecimiento educativo al que asiste o asistió.
Lugar Nacimiento	CH15	Lugar donde nació el individuo. Permite identificar migrantes.
Nivel Educativo	NIVEL_ED	Nivel educativo más alto alcanzado por el individuo (variable recodificada por INDEC que combina CH12 y CH13). Es la variable educativa principal para el modelo.

9 Condición Laboral

9.1 Variables de condición y clasificación laboral

Columna	Origen EPH	Descripción
Categoría Ocupacional	CAT_OCUP	Posición en la estructura de la ocupación. Clasifica según la relación de dependencia.
Tipo de Empleo	EMPLEO	Clasificación oficial del empleo según el INDEC. Indica si el empleo es formal o informal. Esta variable es el target oficial del problema y no debe usarse como feature en el modelo. Usar únicamente para validación y análisis exploratorio (TP1).
Area	SECTOR	Sector de la unidad económica donde trabaja el individuo. Muy correlacionado con la informalidad. Solo usar en EDA y validación.
Pluriempleo	PP03C	Indica si el individuo tenía uno o más empleos la semana de referencia.
Cantidad de Ocupaciones	PP03D	Número de empleos u ocupaciones que tenía la semana pasada.
Sector	PP04A	Tipo de empleador: sector público o privado. El sector público es prácticamente 100% formal, por lo que esta variable es muy discriminante.
Lugar de Trabajo	PP04G	Lugar físico donde el individuo realiza principalmente sus tareas laborales.

9.2 Variables de ingresos

Columna	Origen EPH	Descripción
Ingreso de Ocup. Principal	P21	Monto total de ingresos habituales de la ocupación principal del individuo.
Ingreso Otras Ocupaciones	TOT_P12	Monto de ingresos de otras ocupaciones (secundaria, ocupación previa, etc.).
Ingreso Total Individual	P47T	Suma de todos los ingresos laborales y no laborales del individuo.
Ingresos No Laborales	T_VI	Total de ingresos no laborales del individuo (jubilaciones, pensiones, planes, rentas, etc.).

10 Variables de Jornada Laboral

Las columnas originales de la EPH que registran la frecuencia e intensidad de trabajo (frecuencia de cobro, días por semana, días por mes y horas por día) fueron procesadas y sintetizadas en una única variable derivada: **Horas Mensuales Estimadas**, documentada en la sección siguiente. Las columnas intermedias fueron eliminadas del dataset final para reducir la redundancia.

Nota sobre las variables de jornada laboral:

Las siguientes columnas de la EPH registran información sobre la intensidad y frecuencia del trabajo. Dado que la EPH formula estas preguntas de manera separada para trabajadores **asalariados** e **independientes**, cada concepto tiene dos columnas de origen. Durante la construcción del dataset estas columnas fueron unificadas, procesadas y sintetizadas en la variable **Horas Mensuales Estimadas**, por lo que **no figuran en los archivos provistos**.

Concepto	Asalariados (EPH)	Independientes (EPH)
Frecuencia de cobro	PP08G: ¿A qué período corresponde el cobro?	PP06K: ¿A qué período corresponde lo ganado?
Días por semana	PP08G_DSEM: ¿Cuántos días por semana trabaja?	PP06K_SEM: ¿Cuántos días por semana trabaja?
Días por mes	PP08G_DMES: ¿Cuántos días en el mes?	PP06K_MES: ¿Cuántos días en el mes?
Horas por día	PP08H: ¿A cuántas horas por día corresponde el cobro?	PP06L: ¿A cuántas horas por día corresponde lo ganado?

Para consultar la descripción completa y los valores posibles de cada columna original, referirse al documento “*Diseño de registros y estructura para las bases preliminares Hogar y Personas*”, publicado por el INDEC (noviembre 2025).

11 Variables Derivadas

Estas variables fueron **construidas a partir de las columnas originales** de la EPH mediante transformaciones, clasificaciones o unificaciones. No existen como tales en las bases originales del INDEC.

11.1 Actividad Económica

Origen: Columna PP04B_COD (código CAES-Mercosur de 3–5 dígitos)

Transformación:

1. Se extrajeron los primeros 2 dígitos del código CAES (división de actividad). Para códigos de 2 dígitos (valores < 100), el valor ya representa la división. Para códigos mayores, se toman los primeros 2 dígitos del número completado a 4 dígitos con ceros a la izquierda.
2. Se clasificaron las divisiones en macrosectores según el clasificador ISIC Revisin 4 (con adaptaciones para códigos de Revisión 3 que aún aparecen en la EPH).

Valor	Divisiones CAES incluidas
Agricultura/Ganadería/Silvicultura/Pesca	Divisiones 01–03
Minería	Divisiones 05–09
Industria Manufacturera	Divisiones 10–33
Suministro Energía/Agua	Divisiones 35–39
Construcción	División 40 (y 41–43 en Rev.4)
Comercio	Divisiones 45–48
Transporte/Almacenamiento	Divisiones 49–53
Gastronomía/Alojamiento	Divisiones 55–56
Información/Comunicación	Divisiones 58–63
Finanzas/Seguros	Divisiones 64–66
Inmobiliario	División 68
Servicios Profesionales/Científicas/Técnicas	Divisiones 69–82
Administración Pública/Defensa	División 84
Educación	División 85
Salud/Servicios Sociales	Divisiones 86–88
Arte/Entretenimiento/Recreación	Divisiones 90–93
Otros Servicios	Divisiones 94–96
Servicio Doméstico	Divisiones 97–98

11.2 Variables del Clasificador Nacional de Ocupaciones (CNO)

Origen: Columna PP04D_C0D (código CNO de 5 dígitos)

Estructura del código CNO:

$X_1 \quad X_2 \quad X_3 \quad X_4 \quad X_5$

donde cada dígito codifica una dimensión distinta de la ocupación. Los códigos inválidos (99999, 99998, 99997, 99996) y el valor 1 fueron tratados como NaN. Los códigos de 4 dígitos fueron completados con un cero a la izquierda.

Columna derivada	Dígito CNO	Descripción
Jerarquía de Ocupación	3 ^{er} dígito	Posición dentro de la estructura de mando de la unidad productiva.
Tecnología Utilizada en Ocupación	4 ^o dígito	Tipo de instrumental técnico utilizado en la ocupación.
Calificación	5 ^o dígito	Nivel de complejidad de la ocupación, determinado por las tareas requeridas y no por el nivel educativo del individuo.

11.3 Antigüedad Laboral

Origen: Tres fuentes unificadas en orden de prioridad:

1. PP07A : Antigüedad para trabajadores asalariados en general. **Nota:** Esta columna no aplica a trabajadores del servicio doméstico por diseño del cuestionario EPH.
2. PP04B3_ANO + PP04B3_MES + PP04B3_DIA : Antigüedad para trabajadores del servicio doméstico. La antigüedad en días/meses/años fue convertida a meses y luego categorizada en la misma escala que PP07A.
3. PP05H : Antigüedad para trabajadores independientes (cuenta propia y patrones).

Valor	Descripción
1	Menos de 1 mes
2	De 1 a 3 meses
3	Más de 3 a 6 meses
4	Más de 6 meses a 1 año
5	Más de 1 a 5 años
6	Más de 5 años

11.4 Aporta Jubilación

Origen: Dos fuentes unificadas:

1. PP07H : Descuento Jubilatorio para asalariados: ¿el empleador le hace descuento jubilatorio? Aplica a **todos** los asalariados incluyendo sector público y servicio doméstico. Mayor cobertura que PP07I.
2. PP05I : Tipo Aporte para independientes: recodificado a Sí (Monotributista, Monotributista social, Autónomo) / No (Ninguno).

Descartadas: PP07I fue descartada por ser un subconjunto de PP07H con menor cobertura (solo aplica a asalariados privados no domésticos).

Valor	Descripción
Sí	Tiene descuento/aporte jubilatorio
No	No tiene descuento/aporte jubilatorio

11.5 Tamaño Empresa

Origen: Dos columnas de la EPH unificadas en orden de prioridad:

1. PP04C – “¿Cuántas personas, incluido usted, trabajan allí en total?” Pregunta principal con 12 categorías:

1 = 1 persona	7 = 11 a 25 personas
2 = 2 personas	8 = 26 a 40 personas
3 = 3 personas	9 = 41 a 100 personas
4 = 4 personas	10 = 101 a 200 personas
5 = 5 personas	11 = 201 a 500 personas
6 = 6 a 10 personas	12 = Más de 500 personas
99 = NS/NR → se intenta recuperar con PP04C99	

2. PP04C99 – *Pregunta de rescate*, solo formulada a quienes respondieron NS/NR en PP04C. Solo 3 categorías amplias:

1 = Hasta 5 personas
2 = De 6 a 40 personas
3 = Más de 40 personas
9 = NS/NR → NaN

Proceso de unificación: Ambas columnas fueron armonizadas a **3 niveles comparables** y unificadas mediante `fillna()` (PP04C primero, PP04C99 como respaldo). Las columnas son mutuamente excluyentes: ningún individuo tiene dato en ambas simultáneamente, confirmando que PP04C99 es genuinamente una pregunta de rescate.

Valor final	PP04C incluye	PP04C99 incluye
Hasta 5 personas	Códigos 1–5	Código 1
De 6 a 40 personas	Códigos 6–8	Código 2
Más de 40 personas	Códigos 9–12	Código 3

Nota: El valor “Más de 40 personas” absorbe tanto empresas medianas (41–500) como grandes (>500) por limitación de la escala de PP04C99, que no permite distinguir entre ambos rangos.

Valor	PP04C incluye	PP04C99 incluye
Hasta 5 personas	1, 2, 3, 4, 5 personas	Hasta 5 personas
De 6 a 40 personas	6-10, 11-25, 26-40 personas	De 6 a 40 personas
Más de 40 personas	41-100, 101-200, 201-500, +500 personas	Más de 40 personas

11.6 Horas Mensuales Estimadas

Origen: Cuatro columnas de jornada laboral unificadas previamente:

Frecuencia Cobro (PP08G / PP06K), Días por Semana (PP08G_DSEM / PP06K_SEM), Días por Mes (PP08G_DMES / PP06K_MES) y Horas por Día (PP08H / PP06L).

Lógica de cálculo: La fórmula aplicada depende de la frecuencia de cobro declarada por el individuo. Se utiliza la constante 4,33 semanas/mes (= 52/12):

$$\text{Horas Mensuales} = \begin{cases} \text{Días/semana} \times 4,33 \times \text{Horas/día} & , \text{ si trabaja todo el mes} \\ \text{Días/mes} \times \text{Horas/día} & , \text{ si trabaja menos de todo el mes} \\ \text{NaN} & , \text{ si no hay información suficiente} \end{cases}$$

Valor aproximado	Interpretación
~173 hs/mes	Jornada completa estándar (8 hs × 5 días × 4,33 semanas)
< 87 hs/mes	Subocupado (menos de la mitad de jornada completa)
> 200 hs/mes	Sobreocupado
NaN	Patrón, familiar sin remuneración, o NS/NR en horas o frecuencia

12 Consideraciones Finales

Este documento fue redactado para que los alumnos tengan una referencia clara y accesible del conjunto de datos con el que van a trabajar. Antes de analizar o modelar cualquier variable, conviene entender de dónde viene y cómo fue construida.

Los datos provienen de la **Encuesta Permanente de Hogares (EPH)** del INDEC, que es la fuente oficial de información sobre el mercado de trabajo en Argentina. Por eso, el proceso de curado que se describe en este documento no fue trivial, y entenderlo es parte del aprendizaje.

Ante cualquier duda sobre el significado de una columna o cómo fue construida, consultar este documento primero. Si la duda persiste, acudir el documento oficial del INDEC con el diseño completo de los registros de la EPH.

Para referenciar la fuente en algún trabajo, se debe citar la publicación oficial del INDEC, no este documento. El mismo y los datos originales pueden encontrarse en el siguiente enlace:

<https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos>